

小宋

求职意向：AI 算法工程师 / 大模型应用研究员

电话：138-XXXX-XXXX | 邮箱：xiaosong@demo.com | 地址：某一线城市

【个人评价】

- 拥有 3 段 AI 核心业务实战经验，精通 LLM 微调、RAG 架构优化及多模态算法落地。
- 擅长利用 LoRA/QLoRA 进行低成本模型定制，曾主导多个亿级参数模型的垂直领域适配项目。
- 具备极强的工程化能力，能通过 Python/C++ 实现高性能推理引擎，致力于用算法驱动业务智能化升级。

【教育背景】

- 某理工类顶尖大学（985） | 计算机科学与技术 | 硕士 | 2023.09 – 2026.06
- 研究方向：自然语言处理 (NLP)、大模型对齐技术
- 荣誉奖项：全国大学生数学建模竞赛一等奖、校级“挑战杯”特等奖

【工作经历】

某头部互联网平台 – AI Lab | 算法研究员 | 2025.06 – 至今

- LLM 垂直领域微调：基于 7B/13B 开源基座模型，利用 LoRA 技术在金融/法律垂直语料上进行全量微调，使模型在专业任务上的准确率从 65% 提升至 88% [1]。
- RAG 链路重构：设计并实现了基于 RAG-Fusion 的检索增强生成方案，通过多路召回与重排序算法，将知识库问答的幻觉率降低了 40%，响应速度提升 2 倍 [3]。
- 自动化评测体系：搭建基于 Harness 框架的自动化评测流水线，覆盖逻辑推理、代码生成等 10+ 个维度，为模型迭代提供了量化数据支撑。
- Prompt 工程优化：针对复杂任务拆解设计了 Chain-of-Thought (CoT) 模板，显著提升了模型在处理长文本摘要时的遵循度与连贯性。

某自动驾驶独角兽企业 | AI 算法工程师 | 2024.06 – 2025.05

- 多模态感知融合：负责视觉与激光雷达数据的时序融合算法开发，通过引入 Transformer 架构，将复杂路况下的目标检测 mAP 提升了 5.2%。
- 模型轻量化部署：利用知识蒸馏与 INT8 量化技术，将核心感知模型体积压缩 60%，成功在边缘计算设备上实现 30FPS 的实时推理 [2]。
- 数据闭环建设：参与构建了 TB 级自动驾驶数据挖掘平台，通过主动学习筛选高价值 Corner Case，大幅降低了标注成本。

某顶尖高校智能媒体实验室 | 科研助理 | 2023.06 – 2024.05

- AIGC 图像生成研究：深入探索 Diffusion Model 的原理，复现并改进了 Stable Diffusion 的微调流程，在特定艺术风格迁移任务上取得了 SOTA 效果。
- 论文撰写与发表：协助导师完成多篇顶会论文的仿真实验与数据分析，熟练运用 PyTorch 进行大规模分布式训练。
- 开源社区贡献：积极参与 Hugging Face 社区建设，发布了 2 个经过优化的中文预训练模型，累计下载量超 5000 次。

某 AI 智能客服初创公司 | 核心算法开发 | 2022.06 – 2023.05

- 意图识别引擎开发：基于 BERT 架构开发了高精度的用户意图识别模块，在电商客服场景下实现了 95% 以上的分类准确率。
- 对话状态追踪 (DST)：设计了基于规则与大模型结合的混合 DST 机制，有效解决了多轮对话中的上下文丢失问题，提升了用户留存率。
- 性能调优：通过 CUDA 编程优化了推理过程中的显存占用，使得单卡并发处理能力提升了 3 倍，显著降低了服务器运营成本。

【专业技能】

- 编程语言：熟练掌握 Python、C++，具备优秀的代码规范与工程化落地能力。
- 深度学习框架：精通 PyTorch、TensorFlow，熟悉分布式训练 (DeepSpeed/Megatron) 原理与实践 [4]。

- 大模型技术栈：深入理解 Transformer 架构，熟练掌握 LoRA/QLoRA 微调、RAG 架构设计及 LangChain/LangGraph 应用开发 [5]。
- 工具与平台：熟练使用 Docker、Kubernetes 进行模型容器化部署，熟悉 Linux 环境下的性能调优。